小智语音问答服务

FastAPI 部署指南

文档版本：v1.0

日期：2026-03-30

目录

1. 系统架构 4
1.1 系统架构图 4
1.2 模块说明 4
1.2 数据流 5
2. 环境要求 5
3. 快速安装 5
3.1 克隆代码 5
3.2 创建虚拟环境（推荐） 5
3.3 安装依赖 5
3.4 安装 FFmpeg（音频格式转换需要） 6
4. 配置说明 6
4.1 设置 DeepSeek API Key（必须） 6
4.2 可选配置项（config.py） 6
5. 启动服务 6
5.1 启动 FastAPI 服务（主推荐） 6
5.2 启动 Gradio 图形界面（可选） 7
5.3 查看自动生成的 API 文档 7
6. 接口文档 7
6.1 健康检查 7
6.2 统一问答接口（核心接口） 7
6.3 查询所有 CRM 用户 8

6.4 查询单个用户 8
7. Postman 测试 9
7.1 导入集合 9
7.2 修改服务地址 9
7.3 接口列表 9
7.4 语音问答测试 9
8. 常见问题 13
Q1：启动时提示 DEEPSEEK_API_KEY 未配置 13
Q2：首次启动很慢，卡在"正在加载 Whisper 模型" 13
Q3：语音识别效果不好 13
Q4：语音合成失败（TTS 报错） 14
Q5：端口 8000 被占用 14
Q6：如何查看对话记录 14
项目结构 14

1. 系统架构

1.1 系统架构图

1.2 模块说明

模块	文件	功能
主服务	main.py	FastAPI App，暴露 REST API 接口
ASR 语音识别	services/asr_service.py	使用 faster-whisper，将音频转文字（本地离线）
TTS 语音合成	services/tts_service.py	使用 edge-tts，将文字合成 MP3（需联网）
LLM 大模型	services/llm_service.py	调用 DeepSeek API，生成对话回复
CRM 管理	services/crm_service.py	SQLite 数据库，自动提取并存储用户信息
配置文件	config.py	统一管理所有配置项（密钥、模型、端口等）

1.2 数据流

```
文本输入:  [用户文字] → LLM 回复 → TTS 合成 → 返回 JSON
语音输入:  [录音文件] → ASR 识别 → LLM 回复 → TTS 合成 → 返回 JSON
CRM 流程:  每轮对话 → LLM 提取用户信息（姓名/电话/邮箱）→ SQLite 入库
```

2. 环境要求

项目	要求	
操作系统	Windows 10+ / macOS 12+ / Ubuntu 20.04+	
Python	3.10 或 3.11（推荐 3.11）	
内存	至少 4 GB（ASR 模型加载需要约 1 GB）	
磁盘	至少 2 GB 可用空间（Whisper 模型约 244 MB）	
网络	TTS 和 LLM 需要访问外网	
GPU	可选，有 NVIDIA GPU 可配置 CUDA 加速 ASR	

3. 快速安装

3.1 克隆代码

```
git clone https://github.com/你的用户名/xiaozhi-voice-crm.git
cd xiaozhi-voice-crm
```

3.2 创建虚拟环境（推荐）

```
# Windows
python -m venv venv
venv\Scripts\activate

# macOS / Linux
python3 -m venv venv
source venv/bin/activate
```

3.3 安装依赖

```
pip install -r requirements.txt
```

3.4 安装 FFmpeg（音频格式转换需要）

- Windows：从 https://ffmpeg.org/download.html 下载，解压后将 bin/ 加入系统 PATH
- macOS：brew install ffmpeg
- Ubuntu/Debian：sudo apt-get install ffmpeg

4. 配置说明

所有配置集中在 `config.py`，**禁止将 API 密钥直接写入代码**，使用环境变量传入。

4.1 设置 DeepSeek API Key（必须）

```
# Windows（命令提示符）
set DEEPSEEK_API_KEY=sk-你的密钥

# Windows（PowerShell）
$env:DEEPSEEK_API_KEY="sk-你的密钥"

# macOS / Linux
export DEEPSEEK_API_KEY=sk-你的密钥
```

4.2 可选配置项（config.py）

配置项	默认值	说明
WHISPER_MODEL_SIZE	"base"	ASR 模型大小：tiny/base/small/medium
WHISPER_DEVICE	"cpu"	改为 "cuda" 可使用 GPU 加速
TTS_VOICE	"zh-CN-XiaoxiaoNeural"	语音角色，参考微软 TTS 文档
TTS_RATE	"+10%"	语速，范围 -50% 到 +100%
SERVER_PORT	8000	FastAPI 服务端口
DATABASE_URL	"sqlite:///./crm_database.db"	SQLite 数据库路径
LLM_MAX_TOKENS	500	AI 每次回复最大 token 数

5. 启动服务

5.1 启动 FastAPI 服务（主推荐）

```
python main.py
```

启动成功后输出：

```
INFO:     ⏳ 正在初始化服务...
INFO:     ✅ 所有服务初始化完成，API 已就绪
INFO:     Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
```

5.2 启动 Gradio 图形界面（可选）

```
python gradio_app.py
```

在浏览器访问 `http://127.0.0.1:7860`，即可使用可视化聊天界面。

5.3 查看自动生成的 API 文档

FastAPI 自动生成 Swagger UI，启动后访问：

- Swagger UI（交互式）：http://127.0.0.1:8000/docs
- ReDoc（只读）：http://127.0.0.1:8000/redoc

6. 接口文档

6.1 健康检查

```
GET /health
```

响应示例：

```
{
  "status": "ok",
  "message": "小智语音问答服务运行正常"
}
```

6.2 统一问答接口（核心接口）

```
POST /ask
Content-Type: application/x-www-form-urlencoded   （文本模式）
Content-Type: multipart/form-data                 （语音模式）
```

模式 A — 文本输入

参数	类型	必填
text	string	是（与 audio 二选一）
session_id	string	否（默认 "default"）
return_audio	bool	否（默认 true）

模式 B — 语音输入

参数	类型	必填
audio	file	是（与 text 二选一）

session_id	string	否
return_audio	bool	否

响应格式（两种模式相同）：

```
{
  "session_id": "user_001",
  "input_text": "你好，我叫张三，电话 13800138000",
  "reply_text": "你好呀，张三～ 很高兴认识你呢 (≧▽≦)",
  "reply_audio_base64": "//NExAA...(base64 MP3 数据)...",
  "crm_info": {
    "name": "张三",
    "phone": "13800138000"
  }
}
```

6.3 查询所有 CRM 用户

```
GET /crm/users
```

响应示例：

```
{
  "count": 2,
  "users": [
    {
      "id": 1,
      "session_id": "user_001",
      "name": "张三",
      "phone": "13800138000",
      "email": "zhangsan@qq.com",
      "address": "",
      "company": "",
      "needs": "想了解课程价格",
      "other": "",
      "created_at": "2024-01-15T10:30:00",
      "updated_at": "2024-01-15T10:32:00"
    }
  ]
}
```

6.4 查询单个用户

```
GET /crm/users/{session_id}
```

响应：同上单个用户对象，不存在时返回 404。

7. Postman 测试

7.1 导入集合

7.2 修改服务地址

集合中已设置变量 `base_url = http://127.0.0.1:8000`，无需修改即可使用本地服务。

若服务部署到远程服务器，在集合变量中将 `base_url` 改为服务器 IP：

```
http://你的服务器 IP:8000
```

7.3 接口列表

请求名称	方法	路径
健康检查	GET	/health
文本问答	POST	/ask
文本问答（追加会话）	POST	/ask
语音问答（上传录音）	POST	/ask
查询所有 CRM 用户	GET	/crm/users
查询单个用户	GET	/crm/users/{id}
Swagger 文档	GET	/docs

7.4 语音问答测试

1. 健康检查接口：GET /health

用于快速检查服务是否正常启动，无需参数，直接调用即可。

请求示例：

```
curl http://localhost:8000/health
```

返回示例：

```
{"status": "ok"}
```

测试截图占位：

[截图 1：/health 接口返回结果]

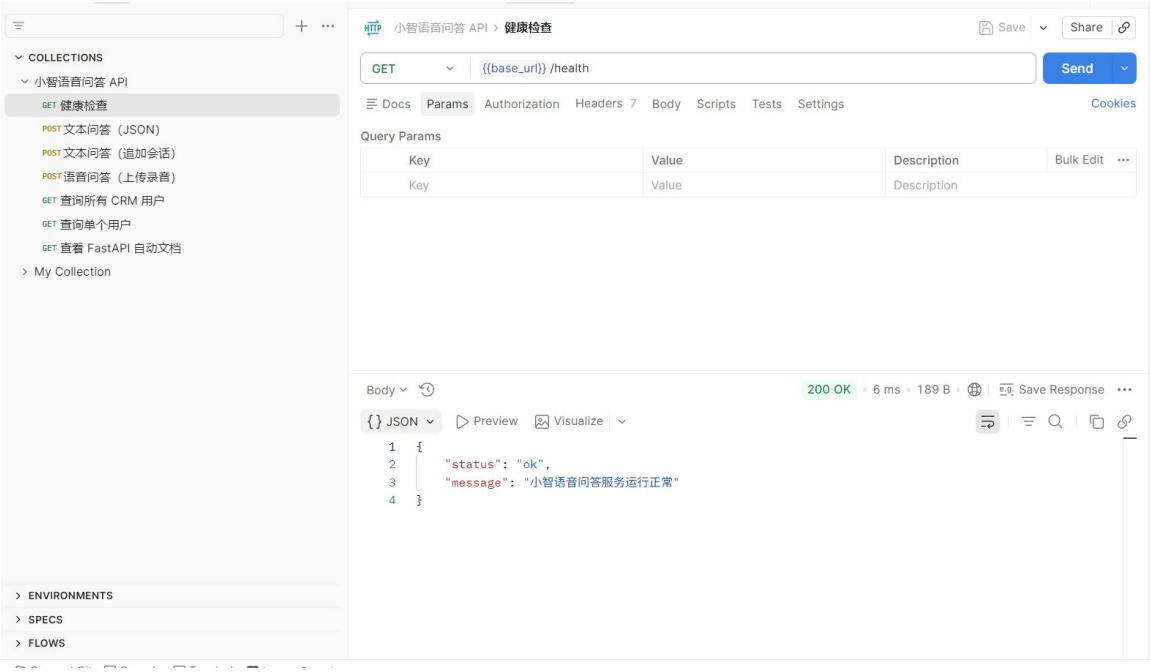

2. 核心问答接口：POST /ask

支持两种输入输出模式，可根据需求选择：

文本问答：传入文本提问，直接返回回答文本

语音问答：传入音频文件，自动完成 ASR 转写、逻辑问答、TTS 转音，返回语音结果

文本问答请求示例：

```
curl -X POST http://localhost:8000/ask \

{

      "session_id": "user_test_001",

      "input_text": "你好，我叫张三，手机号是 13800138000",

      "reply_text": "张三同学～又见面了呢(。•  ㇀•  。)    \n 隐私信息要好
```

```
好保护哦，建议不要重复分享给陌生人呢～",
```

返回示例：

```
    "crm_info": {
        "name": "张三",
        "phone": "13800138000",
        "email": "zhangsan@qq.com",
        "needs": "想了解课程价格"
    }
```

[截图 2：/ask 文本问答接口返回结果]

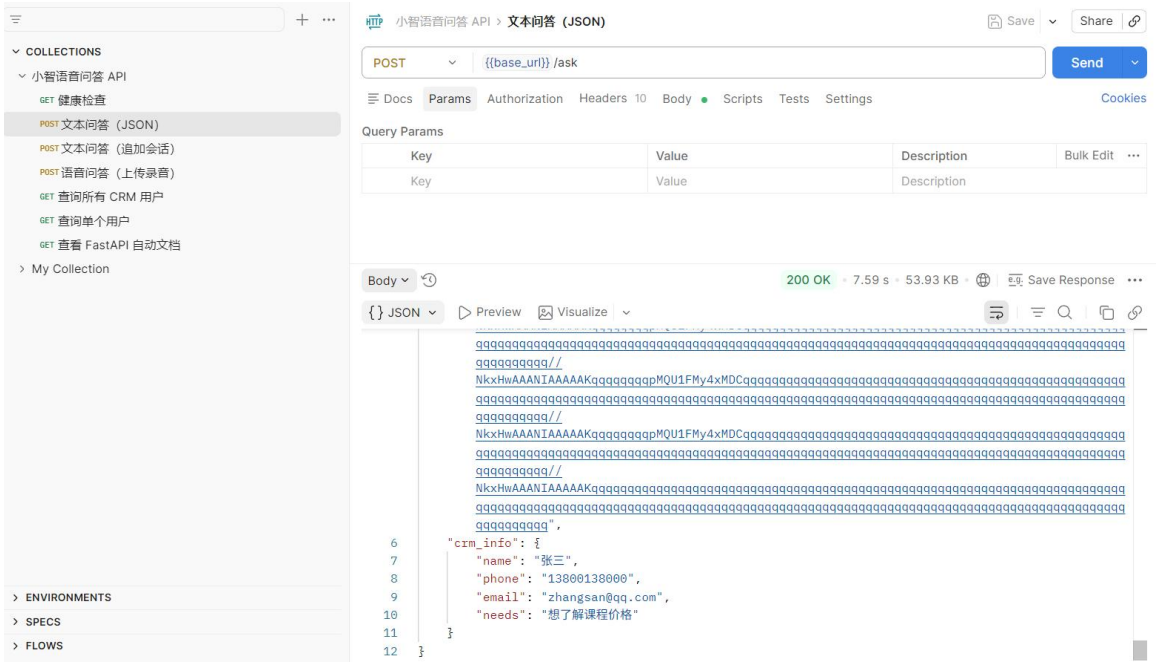

3. CRM 用户查询接口：GET /crm/users

获取 CRM 系统的用户列表，自动提取用户的姓名、电话等信息。

请求示例：

```
curl http://localhost:8000/crm/users
```

返回示例：


```
{
      "id": 1,
      "session_id": "user_test_001",
      "name": "张三",
      "phone": "13800138000",
      "email": "zhangsan@qq.com",
      "address": "",
      "company": "",
      "needs": "想了解课程价格",
      "other": "",
      "created_at": "2026-03-30T12:26:27.787250",
      "updated_at": "2026-03-30T12:27:13.840993"
}
```

[截图 3：/crm/users 接口返回用户列表]

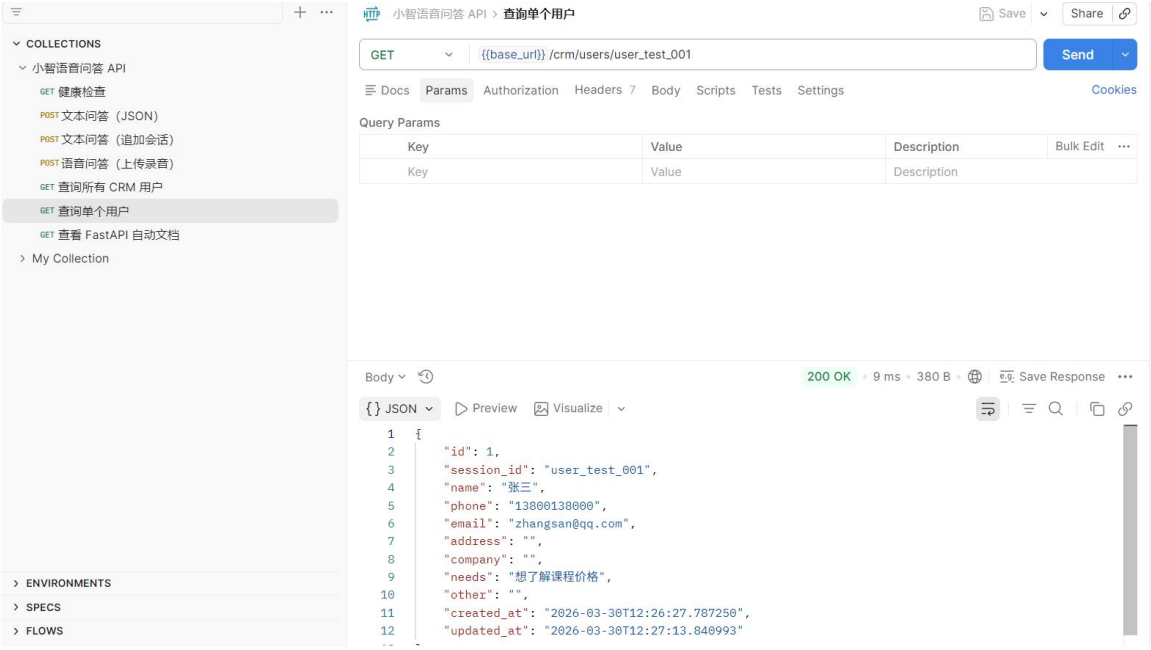

8. 常见问题

Q1：启动时提示 DEEPSEEK_API_KEY 未配置

按照第 4.1 节设置环境变量。注意每次新开终端都需要重新 export，可写入 ~/.bashrc 使其永久生效：

```
echo 'export DEEPSEEK_API_KEY=sk-你的密钥' >> ~/.bashrc
source ~/.bashrc
```

Q2：首次启动很慢，卡在"正在加载 Whisper 模型"

正常现象，首次会自动从 HuggingFace 下载模型文件（约 74 MB）。网络不好可配置镜像：

```
export HF_ENDPOINT=https://hf-mirror.com
```

Q3：语音识别效果不好

修改 config.py 中 WHISPER_MODEL_SIZE 为更大的模型：

```
WHISPER_MODEL_SIZE = "small"   # 244 MB，效果更好
WHISPER_MODEL_SIZE = "medium"  # 769 MB，推荐 GPU 使用
```

Q4：语音合成失败（TTS 报错）

edge-tts 需要访问微软服务器，请检查网络连接。若在国内访问困难，可尝试配置代理。

Q5：端口 8000 被占用

修改 `config.py` 中的 `SERVER_PORT`：

```
SERVER_PORT = 8001  # 改为其他端口
```

Q6：如何查看对话记录

- 方式一：访问 GET /crm/users 接口查看提取的用户信息
- 方式二：点击 Gradio 界面中的 按钮，自动导出 chat_records_readable.txt
- 方式三：用 SQLite 客户端（如 DB Browser for SQLite）打开 crm_database.db

项目结构

```
xiaozhi-voice-crm/
├── main.py                  # FastAPI 主服务（/ask 接口）
├── gradio_app.py            # Gradio 图形界面（可选）
├── config.py                # 统一配置文件
├── requirements.txt         # Python 依赖列表
├── postman_collection.json  # Postman 测试集合
├── architecture.png         # 系统架构图
├── DEPLOY.md                # 本部署指南
└── services/
    ├── __init__.py
    ├── asr_service.py       # 语音识别（ASR）
    ├── tts_service.py       # 语音合成（TTS）
    ├── llm_service.py       # 大语言模型（LLM）
    └── crm_service.py       # CRM 用户管理
```